Proyecto de USTA 2026-II

Dengue, miedo y riesgo
Plan de trabajo de 30 días

Cómo unir el paper de series de tiempo con la teoría del riesgo financiero, y qué corregir antes de construir encima

Dirige

Fechas

Ejecución: 8 de octubre – 6 de noviembre de 2026 · Documento: 8 de octubre de 2026

Pregunta:	£Qué parte del impacto económico del dengue y el chikungunya se asocia a la enfermedad y qué parte al miedo?
Datos base:	SIVIGILA 2020–2025: 748.037 registros de dengue y 419 de chikungunya
Unidad de análisis:	12 regiones de la Encuesta Mensual de Alojamiento (DANE) × mes, 2022–2025
Grupo:	3 personas (P1, P2 y P3), con revisión del docente los viernes
Herramientas:	R, Quarto, Git y asistentes de IA
Entregables:	Paper y presentación en Quarto; repositorio reproducible desde cero
Código:	Repositorio del grupo en GitHub (scripts 01–09), revisado el 8 de octubre
Estado:	Plan aprobado y ajustado tras revisar el código; Google Trends por departamento sin probar

Este documento es la hoja de ruta del grupo para el próximo mes. Reúne el diseño del estudio, las correcciones al paper actual, la aplicación de cada tema del curso, las bases de datos, el software, las reglas de uso de la IA, el cronograma por persona y los criterios con los que el docente da cada fase por terminada. Las fuentes de datos clave se verificaron el 8 de octubre de 2026 (Anexo D). Las cifras del paper se citan tal como las reportó el grupo, y se contrastaron con el código de su repositorio (ğ2).

Índice

1 Resumen ejecutivo **3**
2 Punto de partida **3**
2.1 Hallazgos del paper que el plan conserva . . . 4
2.2 Lo que mostró la revisión del código . . . 4
3 Correcciones al paper **4**
4 Diseño de identificación **6**
4.1 Cuatro contrastes que separan casos y atención . . . 6
4.2 Variables . . . 6
4.3 Unidad de análisis . . . 6
4.4 Vía principal: panel con efectos fijos . . . 6
4.5 Vía de contraste: series nacionales . . . 7
5 Temas del curso aplicados al proyecto **7**
6 Bases de datos **7**
7 Software **10**
8 Uso de la IA **10**
8.1 Usos prácticos recomendados . . . 10
9 Roles y cronograma **12**
10 Riesgos del plan **12**
11 Verificación **12**
A Estructura del repositorio **14**
B Esqueletos de código en R **14**
C Glosario **18**
D Fuentes verificadas el 8 de octubre de 2026 **19**

Cómo leer este documento

Si usted es...	Lea
Docente que revisa los viernes	§1, §9 y §11
P1 · Epidemiología y crédito	§3, §4, §5, §6 y Anexo B
P2 · Econometría	§3, §4 y Anexo B
P3 · Atención y riesgo de mercado	§4, §5, §6 y Anexo B
Todo el grupo	§8 (reglas de IA) y §9

Los términos técnicos están en el glosario (Anexo C).

1. Resumen ejecutivo

Para qué. El grupo ya tiene un paper que modela las series nacionales de dengue y chikungunya del SIVIGILA (2020–2025). Este plan lo convierte, en 30 días, en un estudio de riesgo económico regional que responde una pregunta: *¿cuánto afectan estas enfermedades la economía de las regiones con mayor incidencia, y qué parte del efecto se asocia a la enfermedad misma y qué parte al miedo y los rumores?*

Qué se reutiliza. El repositorio del grupo (scripts 01–09, `renv` y las series semanales por departamento) y las herramientas del paper: Box-Cox, ADF, diferenciación ordinaria y estacional, ACF y PACF, SARIMA, GARCH, VAR, Granger, suavizamiento exponencial y las pruebas de Jarque-Bera, Ljung-Box, Breusch-Pagan y Durbin-Watson. Cada una reaparece con un uso concreto (Tabla 4). Antes hay que corregir los scripts 07–09, porque varios resultados del paper salen de errores de código (§3).

Qué se propone, en cinco ideas.

1. **Tasas y regiones.** Se mide con casos por 100.000 habitantes, no con conteos, y en la unidad que tiene datos económicos mensuales: las 12 regiones de la Encuesta Mensual de Alojamiento (EMA) del DANE.
2. **Separar la atención de los casos.** El *miedo excedente* M es la parte de las búsquedas de alarma en Google Trends que la incidencia local no explica.
3. **Dos vías que se contrastan.** Un panel con efectos fijos (región × mes) y un VAR nacional con descomposición de varianza (FEVD). Si dan el mismo signo y orden de magnitud, el resultado se sostiene.
4. **Un placebo natural.** En 2025, los brotes de chikungunya en La Reunión, China y Cuba tuvieron cobertura en medios y casi cero casos en Colombia: es ṁiedo sin enfermedadż.
5. **El lenguaje del riesgo.** Rendimientos, GARCH, VaR y CVaR con tres simulaciones, CAPM y beta regionales, Markowitz con regiones como activos, y scoring logit/probit con la maquinaria del riesgo de crédito.

Qué se entrega. El viernes 6 de noviembre: el paper y la presentación en Quarto, y un repositorio que cualquier persona del grupo corre desde cero. El docente revisa los viernes 16, 23 y 30 de octubre (§9).

⚠ Lo que hay que saber antes de empezar

- **Los resultados de chikungunya, del VAR y de Granger hay que rehacerlos.** El script 07 no crea las semanas sin casos, así que a la serie mensual de chikungunya le faltan 4 de 72 meses y las fechas quedan corridas. Además, el MAPE del VAR compara meses desalineados (§3).
- **La reducción del 98,4 % del AIC no existe.** `rugarch` reporta el AIC dividido por n: el 6,80 equivale a unos 480, peor que el 414,70 del SARIMA. Además, el modelo que se comparó no es el SARIMA con un GARCH encima.
- **Los microdatos del SIVIGILA están publicados.** El repositorio es público y trae la base cruda completa en `data/processed/`. Se retira el día 1 (§8).
- **Nadie ha comprobado que Google Trends tenga datos por departamento para Colombia.** Se prueba el día 1; si no los tiene, la vía nacional pasa a ser la principal (§10).
- **El diseño mide asociación, no causalidad.** El subregistro de casos infla el efecto del miedo, así que ese efecto se reporta como una cota.

2. Punto de partida

El paper trata dengue y chikungunya por separado, y con razón: 748.037 registros frente a 419, más de tres órdenes de magnitud de diferencia. La Tabla 1 resume sus modelos y lo que este plan hace con cada uno. Las cifras son las de `resumen_econometria_avanzada.csv`, en el repositorio del grupo; aquí no se recalcularon, pero la revisión del código dice cuáles se sostienen.

Tabla 1. Modelos del paper y lo que el plan hace con cada uno.

Evento	Modelo	MAPE	AIC	Qué hace el plan
Dengue	SARIMA$(4,1,0)(1,0,0)_{12}$	5,63 % dentro de muestra, *en escala Box-Cox*	414,70	Se conserva como modelo base y se reevalúa fuera de muestra, en casos
Dengue	ńSARIMA + GARCH(1,1)ż: en el código es un AR(4)-GARCH sin diferenciar	5,63 %, *copiado del SARIMA*	6,80 *por observación* ($\approx$ 480 en total)	No mejora el AIC. Se pasa a la serie semanal, con GJR y EGARCH
Dengue	VAR(4) con chikungunya	48,28 %, *dentro de muestra y desalineado 4 meses*	1.520,32 (conjunto)	Se rehace con 72 meses y se reemplaza por un VAR nacional con incidencia, atención y ocupación
Chikungunya	ARIMA(0,1,0)	infinito (6 meses con 1 caso valen 0 tras Box-Cox)	280,75	Ajustado sobre 68 meses, no 72. Se cambia por un modelo de conteos
Chikungunya	ETS	73,76 %	471,96	También sobre 68 meses. Se reporta MASE; la serie pasa a servir de placebo

2.1. Hallazgos del paper que el plan conserva

- El dengue tiene estacionalidad anual, con picos en el primer semestre y un pico histórico en el segundo trimestre de 2024 (más de 7.500 casos semanales).
- El chikungunya tuvo un brote en 2020 y desde entonces oscila entre 0 y 5 casos semanales: es una serie de conteos bajos.
- Valle del Cauca encabeza ambas enfermedades en conteos (21,47 % y 17,42 % de los casos). El ranking por tasas está por hacer.
- El 99,1 % del faltante es estructural. La imputación con `mice` está hecha, pero es simple: usa la primera de tres bases, con dos iteraciones.

La ausencia de causalidad de Granger entre las dos series no se conserva todavía: el VAR se estimó sobre 68 meses con huecos, y hay que rehacerlo.

2.2. Lo que mostró la revisión del código

El repositorio del grupo trae los scripts 01–09, el `renv.lock` (R 4.5) y las series semanales de casos por departamento, nacionales y por grupo de edad. Se revisaron el código y las series agregadas; los microdatos no se abrieron.

- **Los totales cuadran.** Las series del repositorio suman 748.037 casos de dengue y 419 de chikungunya, igual que el paper.
- **Hay errores de código que cambian resultados.** Las semanas sin casos no existen en las series, el MAPE del VAR está desalineado y el modelo GARCH no es el SARIMA. Van al frente de las correcciones (Tabla 2).
- **Los datos traen sorpresas.** Un código de departamento que no existe, Bogotá sin dengue y series por semana de notificación (ğ6).
- **El repositorio es público y publica los microdatos** (ğ8).
- **El 09 ya existe.** Los scripts nuevos del plan van del 10 al 22 (Anexo A).

3. Correcciones al paper

Hay doce puntos del paper que se corrigen en los días 1 a 4, antes de que el resto del proyecto herede los errores (Tabla 2). Los cuatro primeros son errores de código, y la columna ńDóndeż da el script y la línea en el repositorio. P1 corrige el 07 y hace los puntos 10 y 11; P2 rehace el 08 y el 09 con las series corregidas y hace el resto.

> **Por qué 6,80 no se compara con 414,70.** `rugarch` calcula
>
> $$\mathrm{AIC}_{\texttt{rugarch}} = \frac{-2\ln L + 2k}{n},$$

Tabla 2. Las doce correcciones al paper, en orden de gravedad.

#	Lo que dice el paper	Problema	Dónde	Corrección
1	Modelos de chikungunya, VAR y Granger sobre la serie mensual 2020–2025	`count()` no crea las semanas sin casos. A chikungunya le faltan 4 meses (oct. 2020; jun., ago. y sep. 2025), y `ts()` trata los 68 como seguidos. El VAR descarta esos meses también para dengue	07:55, 07:61, 09:53	Completar con ceros el calendario de 314 semanas (Anexo B, B.1) y rehacer ADF, SARIMA, ETS, VAR y Granger
2	SARIMA + GARCH baja el AIC de 414,70 a 6,80 (−98,4 %)	`rugarch` divide el AIC por n: $6{,}80 \times 71 \approx 483$. El modelo es un AR(4) sobre el nivel Box-Cox, sin diferenciar, sin parte estacional y sin media: no es el SARIMA. Su MAPE se copia del SARIMA	09:129, 09:153, 09:242	Retirar la afirmación. GARCH sobre los residuos del SARIMA, o en la serie semanal (punto 9); comparar fuera de muestra
3	VAR con MAPE de 48 %; el test de *encompassing* favorece al SARIMA	`fitted()` del VAR tiene $n - p$ filas y se resta de un vector de n: R recicla y compara el mes $t + 4$ con el t. El *encompassing* tiene el mismo desfase y mezcla escala Box-Cox con casos	09:203, 09:251	Alinear (descartar los p primeros meses reales) y comparar en la misma escala
4	MAPE de 5,63 % del SARIMA	Está en escala Box-Cox, no en casos, y dentro de muestra. La columna ńútilż de la tabla está escrita a mano	09:230, 09:285	`auto.arima(lambda = "auto", biasadj = TRUE)` y `accuracy()` en una ventana reservada: MASE en casos para todos los modelos
5	Breusch-Pagan, $p = 0{,}004$, en los residuos del SARIMA	Breusch-Pagan necesita regresores; no prueba heterocedasticidad condicional	08:125	ARCH-LM (`FinTS::ArchTest`) o McLeod-Li, que son las que justifican el GARCH
6	Durbin-Watson de 2,06	No es válido con términos AR (variable dependiente rezagada)	08:129	Breusch-Godfrey, o Ljung-Box con `fitdf = p + q` (lo hace `checkresiduals()`)
7	Chikungunya: ADF estacionaria y modelo ARIMA(0,1,0)	Las dos cosas se contradicen, y la serie son conteos bajos: de 0 a 23 casos por semana	08	INGARCH Poisson o binomial negativa (`tscount`)
8	AIC del VAR (1.520,32) frente a los univariados	Es una verosimilitud conjunta: no se compara	09	Evaluar por pronóstico fuera de muestra
9	GARCH(1,1) con 72 meses	Es frágil, y Nyblom (3,189 > 2,59) y sign bias ya muestran inestabilidad y asimetría	09:129	Serie semanal (unos 310 datos), GJR-GARCH y EGARCH, quiebres con `strucchange`
10	Valle, Santander y Tolima como los más afectados	El ranking usa conteos, e incluye 1.600 casos con un código de departamento que no existe (ń01ż)	04	Tasas por 100.000 habitantes con las proyecciones del DANE, sin el código 01
11	Imputación con `mice` (bosques aleatorios)	$m = 3$ y `maxit = 2`, y solo se usa la primera base. No afecta las series, pero sí el scorecard, que usa el estrato	06:244, 06:300	En el scorecard, estrato faltante como categoría propia; o $m \geq 5$ con `pool()`
12	La caída de 2025 se debe a la inmunidad de rebaño	Con cuatro serotipos hay otras explicaciones	paper	Redactarlo como hipótesis

así que, con $n \approx 71$, el AIC en la escala de `arima()` es $6{,}80 \times 71 \approx 483$, mayor que 414,70. Y aun en la misma escala, dos verosimilitudes solo se comparan con la misma serie y el mismo modelo de la media. En el 09 no pasa: el SARIMA usa la serie diferenciada, y el GARCH el nivel con un AR(4).

Por qué faltan meses. `count()` solo devuelve las combinaciones que aparecen en los datos: una semana sin casos no queda con cero, sino que no existe. En dengue nacional no se nota, porque todas las semanas tienen casos. En chikungunya sí: 197 de 314 semanas tienen fila, y la serie mensual queda con 68 meses. Por departamento pasa lo

> mismo, incluso en dengue: según el departamento, hay entre 149 y 314 semanas con fila. Ninguna serie departamental se usa sin completarla antes.

4. Diseño de identificación

Para separar enfermedad de miedo hacen falta dos variables que no se muevan juntas todo el tiempo: una que mida los casos y otra que mida la atención que la epidemia local no explica (Figura 1).

4.1. Cuatro contrastes que separan casos y atención

Tabla 3. Episodios y unidades que identifican el efecto.

Episodio	Casos	Atención	Qué identifica
Chikungunya 2025	casi nulos en Colombia	alta (por verificar)	miedo sin enfermedad, en la serie nacional
Bogotá, 2022–2025	cero por ocurrencia	la que haya	atención sin enfermedad local, dentro del panel
Dengue 2024 (El Niño)	pico histórico	alta	el efecto conjunto que se descompone
Dengue 2020 (COVID)	media	baja	enfermedad con poca atención; solo robustez

4.2. Variables

- **Incidencia** I_{rt}: casos por 100.000 habitantes en la región r y el mes t, por departamento de ocurrencia y fecha de inicio de síntomas. Las series actuales del repositorio van por semana de notificación: esa versión mide lo que el INS reporta y la gente ve, y sirve de robustez en la regresión auxiliar.
- **Atención** A_{rt}: Google Trends con términos de alarma (ńbrote dengueż, ńepidemia dengueż, ńmuertes por dengueż, ńchikungunyaż), más el volumen y el tono de noticias de GDELT, que solo es nacional.
- **Búsquedas de síntomas** S_{rt}: ńsíntomas dengueż. No miden miedo, porque las hacen los enfermos, así que van del lado de la enfermedad.

El miedo excedente es el residuo de la regresión auxiliar (Frisch-Waugh):

$$A_{rt} = \sum_{k=0}^{3} \phi_k \, I_{r,t-k} + \psi \, S_{rt} + s_{r,m(t)} + M_{rt}.$$

Hay tres cautelas sobre M:

- El subregistro de casos queda dentro de M e infla su efecto.
- M es un regresor generado, así que el bootstrap repite los dos pasos juntos.
- Se habla de efecto ńasociado a la atenciónż, no de efecto causal del miedo.

4.3. Unidad de análisis

La unidad son las 12 regiones de la EMA, por mes, en 2022–2025: 576 observaciones. La EMA no publica todos los departamentos: Bogotá, Antioquia, Cartagena y San Andrés van solos y el resto va agrupado (por ejemplo, Costa Caribe). La incidencia se agrega a esas regiones ponderando por población. El resultado principal es la ocupación hotelera, el canal más sensible al miedo.

Bogotá no tiene casos de dengue por ocurrencia en 2020–2025: está a 2.600 metros, sin el mosquito transmisor. En el panel entra con $I = 0$, así que sus movimientos de atención identifican θ sin enfermedad local. Como robustez, θ se estima con y sin Bogotá.

El periodo 2020–2021 sale del modelo principal porque el COVID colapsó al mismo tiempo el reporte de casos, la economía y la atención. Entra solo como prueba de robustez.

4.4. Vía principal: panel con efectos fijos

$$Y_{rt} = a_r + g_t + s_{r,m(t)} + \sum_{k=1}^{3} b_k \, I_{r,t-k} + \sum_{k=1}^{3} \theta_k \, M_{r,t-k} + \gamma' C_{r,t-1} + e_{rt}$$

- g_t son efectos fijos de año-mes, y $s_{r,m(t)}$ es la estacionalidad propia de cada región.
- Solo entran rezagos, para evitar la causalidad inversa: el turismo también trae casos y más reporte.

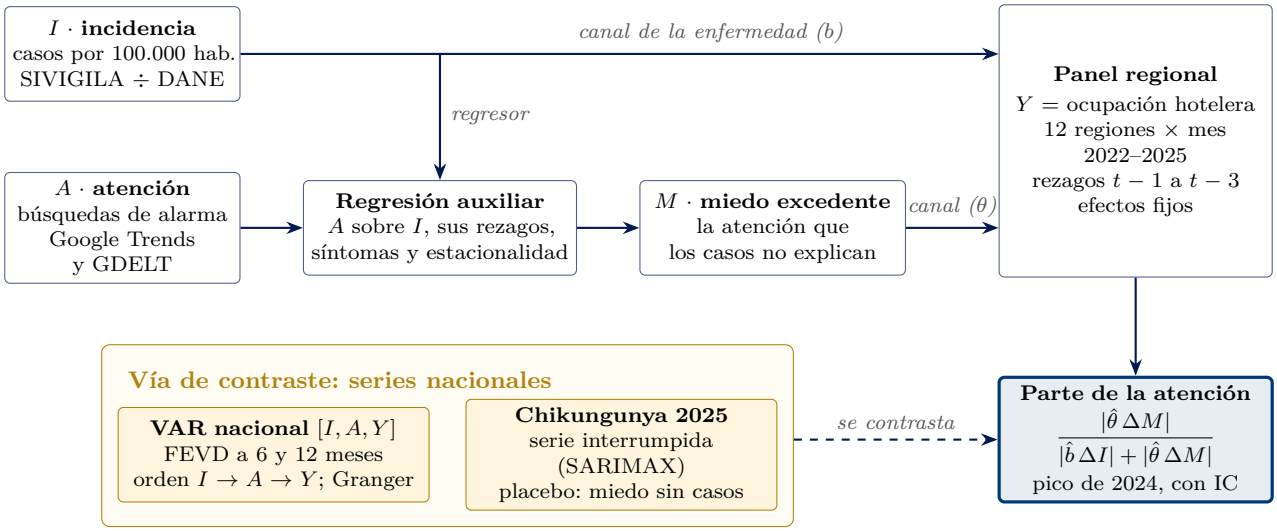


Figura 1. Diseño de identificación. En la vía principal, la incidencia entra directo al panel y además limpia la atención; lo que sobra es el miedo excedente M. La vía nacional estima la misma participación por otro camino, y las dos se comparan.

- $C_{r,t-1}$ es el clima local rezagado (lluvia y temperatura). Va como control y nunca como instrumento, porque El Niño 2023–24 movió tanto los casos como la economía. El ONI entra solo interactuado con la región, porque por sí mismo es colineal con g_t.
- Errores Driscoll-Kraay (`fixest`, `vcov = "DK"`), y como contraste, errores agrupados por región.

La participación de la atención en el pico de 2024 se calcula con las contribuciones ajustadas:

$$\pi_{\text{atención}} = \frac{|\hat{\theta}\,\Delta M|}{|\hat{b}\,\Delta I| + |\hat{\theta}\,\Delta M|},$$

donde $\hat{b} = \sum_k \hat{b}_k$, $\hat{\theta} = \sum_k \hat{\theta}_k$, y ΔX es el valor medio de X en el pico de 2024 menos su media en los mismos meses de 2022–2023. El intervalo sale del bootstrap de dos pasos.

4.5. Vía de contraste: series nacionales

VAR nacional $[I, A, Y]$, con el clima como exógeno y el orden de Cholesky $I \to A \to Y$. La FEVD a h meses da la fracción de la varianza del error de pronóstico de Y que viene del choque j:

$$\omega_{Y \leftarrow j}(h) = \frac{\sum_{i=0}^{h-1} \left(\mathbf{e}_Y' \,\Theta_i\, \mathbf{e}_j\right)^2}{\sum_{i=0}^{h-1} \mathbf{e}_Y' \,\Theta_i \Theta_i'\, \mathbf{e}_Y},$$

con Θ_i las respuestas al impulso ortogonalizadas. Se reporta con $h = 6$ y $h = 12$. La prueba de Granger dice además si la atención anticipa los casos, es decir, si el rumor es un indicador adelantado.

Serie interrumpida de chikungunya 2025. Un SARIMAX ajustado hasta junio de 2025 da el contrafactual de la ocupación y de la atención, y el efecto es la suma de los desvíos entre lo observado y lo pronosticado en julio–diciembre. Los choques con cobertura en medios fueron La Reunión (marzo–abril), Foshan en China (brote declarado el 9 de julio), las alertas de la OPS (13 y 28 de agosto) y Cuba (julio–diciembre, con pico en octubre–noviembre). Este choque es nacional: en el panel lo absorbería g_t, y por eso se analiza en la serie nacional.

5. Temas del curso aplicados al proyecto

Cada tema del curso tiene una aplicación concreta (Tabla 4). Los de nivel ● Núcleo sostienen la pregunta. Los de nivel ● Aplicación son obligatorios porque cubren el curso, pero van sin pretensión causal y con tiempo acotado. Granger, IRF y FEVD no aparecen en la tabla porque son la vía de contraste de la ğ4.

6. Bases de datos

La base que decide el alcance es Google Trends por departamento: nadie ha confirmado que exista para Colombia, así que se prueba el día 1. Las demás fuentes clave se verificaron el 8 de octubre de 2026 (Tabla 5; detalle en el Anexo D).

Tabla 4. Aplicación de cada tema del curso, lo que se reutiliza del paper y los paquetes de R.

Tema	Nivel	Aplicación concreta	Se reutiliza	Paquetes
Gráficos de línea y de velas	● Aplicación	Velas semanales de casos: apertura, máximo, mínimo y cierre de los casos diarios por fecha de inicio de síntomas. Velas de ICOLCAP	series semanales	`quantmod`, `tidyquant`
Soportes, resistencias y tendencia	● Aplicación	El canal endémico del INS (método de Bortman) como bandas de soporte y resistencia, frente a Bollinger. Cruces de SMA y EMA y MACD como alerta temprana, frente a las alertas oficiales	diferenciación estacional; ACF y PACF	`TTR`
Rendimientos	● Núcleo	$\log(I_t/I_{t-1})$ es la tasa de crecimiento epidémico, el análogo de un rendimiento logarítmico. También para la ocupación y las acciones	Box-Cox	`Performance Analytics`
ARCH y GARCH	● Núcleo	ARCH-LM, luego GARCH, GJR y EGARCH semanal, con M como regresor externo en la ecuación de varianza: £la atención vuelve más volátil la serie?	su GARCH	`rugarch`, `FinTS`
Beta, CAPM, riesgo sistemático y no sistemático	● Aplicación	CAPM regional: ocupación de cada región frente a la nacional; £el dengue explica el riesgo idiosincrático? CAPM bursátil con `bvc_diario.csv` y un factor de atención	Jarque-Bera, Breusch-Pagan y Durbin-Watson sobre la regresión	`lm`, `sandwich`
Beta de un portafolio	● Aplicación	$\beta_p = \sum_i w_i \beta_i$, con pesos por PIB o por cuartos hoteleros de cada región	—	R base
Estudio de eventos	● Aplicación	Rendimientos anormales acumulados de ICOLCAP y acciones alrededor de los picos de atención. Lo esperable es un nulo, que sirve de placebo	SARIMA como modelo de lo ńesperadoż	`Performance Analytics`
VaR, CVaR y simulaciones	● Núcleo	Pérdida semanal = casos × costo por caso + pérdida asociada a la atención. VaR y CVaR al 95 y 99 % por simulación histórica, Montecarlo (`ugarchsim`) y bootstrap por bloques. Backtesting de Kupiec y Christoffersen	SARIMA y GARCH	`rugarch`, `boot`
Media-varianza y Markowitz	● Aplicación	Regiones como activos de un portafolio de exposición (aseguradora o cadena hotelera). Fronteras en meses epidémicos y normales. Isomedia e isovarianza con 3 regiones. Frontera bursátil como contraste	—	`quadprog`
Logit y probit	● Núcleo	Scorecard de severidad con los 748.037 registros: P(hospitalización), con `pac_hos`, y AUC, KS y Gini. P(dengue grave) y P(muerte) solo si se descargan los eventos 220 y 580	variables preparadas en 02	`glm`, `pROC`, `marginaleffects`
Probit de alerta temprana	● Aplicación	P(zona de brote) por región y semana, según la atención rezagada y el clima. Es lo más cercano al objetivo del repositorio: predecir en zonas críticas	canal endémico	`glm`, `pROC`
Riesgo de crédito	● Aplicación	Proporción de la cartera en categorías B a E por departamento y trimestre (Superfinanciera). Estrés de pérdida esperada $EL = PD \times LGD \times EAD$ en un escenario epidémico	VAR y Granger	`fixest`, `httr2`

Tabla 5. Bases de datos del proyecto y su estado al 8 de octubre de 2026.

Base	Para qué	Frecuencia y nivel	Acceso desde R	Estado
SIVIGILA, microdatos del INS: dengue 210 y chikungunya 217	incidencia y hospitalización	individual; el repositorio ya trae las series semanales por departamento	`readxl`, `here`	Disponible
SIVIGILA: dengue grave (220) y mortalidad por dengue (580)	severidad del scorecard	individual	`readxl`	Por descargar
INS: informes de evento de dengue y alertas	canal endémico y fechas de alerta	semanal	manual	Verificada
DANE: proyecciones de población departamental (CNPV 2018)	tasas por 100.000 habitantes	anual	`readxl`	Por buscar
DANE EMA: ocupación hotelera	resultado principal	mensual, 12 regiones; empalme MMH → EMA en 2020	`readxl`	Verificada
DANE: PIB departamental	pesos de portafolio	anual	`readxl`	Por buscar
Superfinanciera: colocaciones por municipio (datos.gov.co, `u2wk-tfe3`)	riesgo de crédito	trimestral, por departamento y municipio, categorías A a E	`httr2` (API Socrata)	Verificada
Google Trends (`geo = "CO-VAC"`, ...)	atención	semanal en ventanas de hasta 5 años: dos descargas solapadas y reescaladas	`gtrendsR` o CSV manual	**Por probar**
GDELT DOC 2.0 (`timelinevol`, `timelinetone`)	volumen y tono de noticias	diaria desde 2017, solo nacional	`httr2`, `jsonlite`	Verificada
NASA POWER	lluvia y temperatura por capital	diaria	`nasapower`	Por buscar
NOAA ONI	El Niño y La Niña	mensual	`readr`	Por buscar
`bvc_diario.csv` del curso de Teoría del Riesgo (ECOPETROL, BOGOTA, GRUPOSURA, ISA, ICOLCAP; 2018–2025)	CAPM bursátil y estudio de eventos	diaria	`readr`	Disponible
Tasa libre de riesgo: IBR o TES del Banco de la República	CAPM	diaria	`readr`	Disponible
Costo por caso de dengue en Colombia (literatura de carga económica)	VaR de pérdida	constante	se cita la fuente	Por buscar
Opcional: GEIH e IPC por ciudad, Aerocivil, CITUR	resultados alternos	mensual	`readxl`	Por buscar

Lo que dejó la verificación del 8 de octubre.

- La cartera de la Superfinanciera no trae columna de cartera vencida. Por eso se usa la proporción en categorías B a E, que da unos 24 trimestres.
- `gtrendsR` sigue en CRAN, pero en 2025 se reportaron errores 429 y resultados vacíos: hay que tener la descarga manual como respaldo.
- La GEIH por ciudad es un trimestre móvil, y eso mete autocorrelación artificial. Por eso queda como opcional.
- El docente comparte `bvc_diario.csv`, con sus anomalías documentadas en su manifiesto.

Lo que dejó la revisión del repositorio. Se miraron el código y las series agregadas, no los microdatos.

- **El código ń01ż no es un departamento.** No existe en la DIVIPOLA y tiene 1.600 casos de dengue. Lo más probable es que sean casos ocurridos en el exterior; se confirma con `cod_pais_o` y se excluye de las tasas.
- **Bogotá no tiene dengue por ocurrencia** (código 11). Es una unidad útil del panel (ğ4).
- **Las series van por semana de notificación**, y su fecha semanal es aproximada (año + 7 días por semana, 07:49). Para la incidencia se

reconstruyen por inicio de síntomas, con las fechas diarias `ini_sin` y `fec_not`.

- **El 07 no filtra la variable `ajuste`.** Si la base trae casos descartados (6) o errores de digitación (D), los conteos están inflados. El 03 ya imprime `table(ajuste)`; el total de 2024 se compara con el que publicó el INS.
- **La edad viene en la unidad de `uni_med`** (años, meses o días), y el 02 y el 07 la tratan como años: un bebé de 30 días cae en el grupo ńAdulto (18+)ż. Antes del scorecard se pasa a años (Anexo B, B.7).
- **Solo se descargaron los eventos 210 y 217.** Sin el 220 y el 580, el scorecard se limita a la hospitalización.

7. Software

Todo corre en R 4.5, la versión del `renv.lock` que el grupo ya tiene, con Quarto para el paper. Los paquetes nuevos se agregan a ese `renv` con `renv::snapshot()`. El `entorno/instalar.R` del curso de Teoría del Riesgo sirve de lista de referencia: ya trae `rugarch`, `PerformanceAnalytics`, `quadprog` y `pROC` (Tabla 6).

Tabla 6. Herramientas y paquetes por módulo.

Módulo	Herramientas y paquetes
Base	R 4.5, RStudio o Positron, Quarto, Git y GitHub, `renv` (ya en el repositorio)
Datos	`tidyverse`, `here`, `lubridate`, `janitor`, `readxl`, `httr2`, `jsonlite`, `gtrendsR`, `nasapower`, `sf`
Econometría	`forecast`, `tseries`, `urca`, `lmtest`, `sandwich`, `car`, `FinTS`, `vars`, `fixest`, `strucchange`, `tscount`
Riesgo	`quantmod`, `TTR`, `tidyquant`, `PerformanceAnalytics`, `rugarch`, `quadprog`, `boot`, `pROC`, `marginaleffects`
Texto e IA (opcional)	`ellmer`, `syuzhet` (léxico NRC en español), `tidytext`, `irr`
Asistentes	Claude, ChatGPT o Copilot en RStudio

`fwildclusterboot` salió de CRAN en mayo de 2024, así que los errores robustos del panel van con `fixest` o con `sandwich::vcovPL`.

8. Uso de la IA

El grupo va a usar la IA de forma intensiva. La regla de fondo es simple: la IA escribe código y el grupo verifica cada número.

Reglas

1. **Ninguna cifra sin script.** Ninguna cifra entra al paper si no sale de un script que corre desde cero; Quarto las inserta en el texto.
2. **Nada de microdatos a la IA ni en el repositorio.** Del SIVIGILA solo se le pasan a la IA agregados por región y semana, y el código. En GitHub solo van el código y los agregados.
3. **Manifiesto de datos.** Cada base lleva URL, fecha de descarga y huella SHA-256. Toda fuente que proponga la IA se abre y se verifica antes de usarla.
4. **Bitácora de IA.** Se anota qué se pidió, qué se aceptó, qué se descartó y por qué.
5. **Interpretaciones contra la salida.** Toda lectura de una prueba que proponga la IA (p-valor, signo, rezago) se contrasta con la salida de R antes de escribirla.

Hoy la regla 2 no se cumple. El repositorio es público y tiene versionados `data/processed/dengue_crudo.rds` (37 MB) y `chikungunya_crudo.rds`. Son la unión cruda de las bases del SIVIGILA, con todas sus columnas: fecha de nacimiento, municipio de residencia y pertenencia étnica, entre otras. Entraron en el primer *commit* (21 de septiembre), antes de que se corrigiera el `.gitignore`, y un archivo ya versionado no sale porque el `.gitignore` lo excluya. El README dice lo contrario: que los datos crudos no se incluyen. También está `.RDataTmp` (11,8 MB), un temporal de sesión que puede contener datos.

- **Día 1 (P1):** `git rm -cached` de los tres archivos, `.RDataTmp` al `.gitignore`, y *push*.
- **Decisión del docente y el grupo:** los archivos siguen en el historial. Borrarlos de ahí exige reescribirlo (`git filter-repo`) y que todos vuelvan a clonar. El INS publica estas bases, pero que el grupo las republique en su propio repositorio es otra cosa.

8.1. Usos prácticos recomendados

- **Descargas.** El código de las consultas a GDELT, Socrata y NASA POWER, y el empalme de las dos ventanas de Google Trends. Luego se compara una cifra contra la fuente.

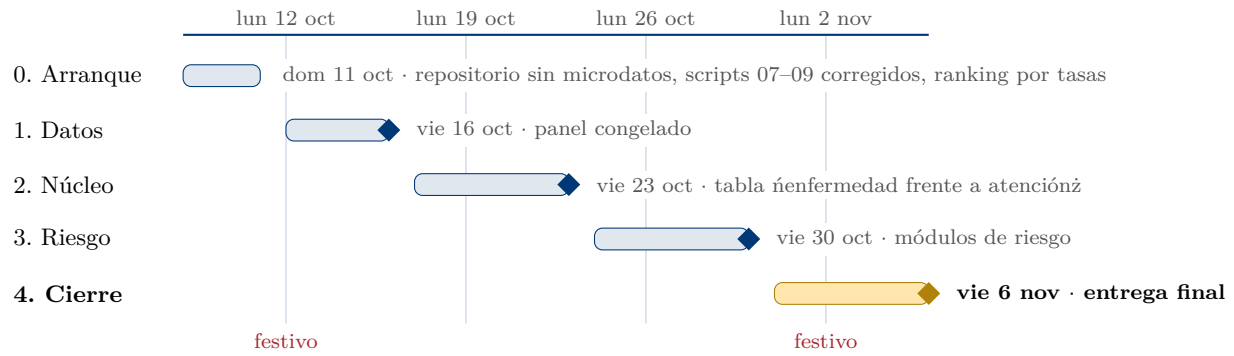


Figura 2. Cronograma de las cinco fases. Cada rombo es una revisión con el docente; el lunes 12 de octubre y el lunes 2 de noviembre son festivos.

Tabla 7. Tareas por persona y fase, con el entregable que cierra cada fase.

Fase	P1	P2	P3	Entregable
0. Arranque jue 8 – dom 11 oct	Sacar los microdatos del repositorio; corregir el 07 (semanas con cero); revisar `ajuste` y el código 01; tasas por 100.000 habitantes y ranking	Correcciones 2 a 9: rehacer el 08 y el 09 con las series completas	Prueba de Google Trends con `geo = "CO-VAC"` y una consulta a GDELT; decide el plan B	Repositorio sin microdatos y con manifiesto; 07–09 corregidos; ranking por tasas; prueba de acceso
1. Datos lun 12 – vie 16 oct	Series semanales por inicio de síntomas; descarga de los eventos 220 y 580; canal endémico; velas, SMA, EMA y Bollinger	Panel EMA × mes con población, clima y ONI; Box-Cox, ADF/KPSS, ACF/PACF	Atención con dos descargas solapadas; GDELT; construcción de M	**Vie 16 oct:** panel congelado, con diccionario y manifiesto; figuras técnicas
2. Núcleo sáb 17 – vie 23 oct	Scorecard logit/probit: AUC, KS, Gini y efectos marginales	Panel con efectos fijos y bootstrap de dos pasos; serie interrumpida de chikungunya 2025	GARCH, GJR y EGARCH semanal con M en la varianza; estudio de eventos	**Vie 23 oct:** tabla ńenfermedad frente a atenciónż con intervalos; resultado del placebo
3. Riesgo sáb 24 – vie 30 oct	Probit de alerta temprana; cartera por departamento y estrés de pérdida esperada	VAR nacional, FEVD y Granger; CAPM regional y beta de portafolio	VaR y CVaR por tres métodos; Kupiec y Christoffersen; Markowitz por régimen	**Vie 30 oct:** módulos de riesgo con tablas y figuras finales
4. Cierre sáb 31 oct – vie 6 nov	Robustez: con 2020–21, otros términos de búsqueda, otro orden de Cholesky	Métodos y resultados en Quarto	Introducción, conclusiones y presentación	**Vie 6 nov:** paper y presentación; otra persona corre todo desde cero

- **De ecuación a código.** El panel, la FEVD y el bootstrap de dos pasos de la ğ4. El Anexo B trae esqueletos para empezar.
- **Lectura de salidas.** Pedir que explique una salida de `rugarch` o `vars`, y contrastarla con la documentación del paquete.
- **Revisión de código.** Pedirle que busque rezagos mal alineados, fugas de información en la validación, semillas sin fijar y combinaciones que faltan tras un `count()`. Son justo los errores que tenían los scripts 07 y 09.
- **Redacción.** Borradores de métodos a partir de las tablas finales; las cifras las pone Quarto.
- **Clasificación de titulares** (opcional). Si se mide la alarma de los titulares con la IA, se compara con 100 titulares codificados a mano;

con kappa $< 0{,}6$ se usa solo el léxico NRC.

9. Roles y cronograma

Cada persona lleva una línea de trabajo, y el docente revisa los entregables los viernes. Los datos se congelan el viernes 16 de octubre y el análisis el lunes 2 de noviembre (Figura 2 y Tabla 7).

- **P1, Epidemiología y crédito.** Es la única persona que maneja los microdatos, y la que los saca del repositorio público. Corrige el script 07 y hace tasas, series semanales, canal endémico, análisis técnico, scorecard logit/probit, probit de alerta y riesgo de crédito.
- **P2, Econometría.** Rehace los scripts 08 y 09 y hace las demás correcciones al paper, el panel EMA, la estacionariedad, el panel con efectos fijos, la serie interrumpida, VAR, FEVD y Granger, y el CAPM regional.
- **P3, Atención y riesgo de mercado.** Hace Google Trends y GDELT, el miedo excedente M, el GARCH semanal, el estudio de eventos, VaR, CVaR y backtesting, y Markowitz.

> ✂ **Plan de recorte.** Si el grupo va atrasado el viernes 23 de octubre, se cae en este orden: la frontera bursátil, el estudio de eventos y el panel de crédito, que queda solo como estrés de pérdida esperada. El probit de alerta temprana no se recorta: es lo más cercano al objetivo con el que nació el repositorio, predecir en zonas críticas. Todos los temas siguen cubiertos con su versión mínima de la Tabla 4.

10. Riesgos del plan

El riesgo que más cambia el proyecto es que Google Trends no tenga datos por departamento. Cada riesgo tiene una respuesta decidida desde ya (Tabla 8).

Tabla 8. Riesgos del plan y respuesta.

Riesgo	Respuesta
Google Trends no tiene datos por departamento	La atención nacional se interactúa con la exposición de cada región (incidencia histórica o peso del turismo), y la vía nacional pasa a ser la principal
`gtrendsR` falla con errores 429	Descarga manual de CSV desde `trends.google.com`
Solo hay 12 regiones, y Driscoll-Kraay es poco fiable con tan pocas	Errores agrupados por región y bootstrap por bloques como contraste; los VAR quedan nacionales
El COVID domina 2020–2021	Muestra principal 2022–2025
El clima mueve los casos y la economía	Clima rezagado como control, más estacionalidad por región; nunca como instrumento
Los efectos reales son pequeños y hay poca potencia	Se reportan intervalos y cotas, no solo p-valores, con lenguaje de asociación
La IA inventa fuentes o cifras	Manifiesto de datos y reproducibilidad obligatoria (ğ8)
Los microdatos siguen en el historial público del repositorio	Se sacan del árbol el día 1; el docente y el grupo deciden si se reescribe el historial (ğ8)
Con las series corregidas cambian conclusiones del paper	Se reportan los resultados nuevos y se dice qué cambió y por qué; no se defiende el resultado anterior

11. Verificación

El docente da el proyecto por terminado cuando se cumplen estas cinco condiciones:

- ☐ **Cordura de datos.** Cada serie tiene sus 314 semanas y 72 meses, con los ceros explícitos. La suma por departamentos da el total nacional: hoy, 748.037 de dengue y 419 de chikungunya, contando los 1.600 casos del código 01; si se filtran casos descartados, el total nuevo queda documentado. La tasa de 2024 de un departamento coincide con la que publicó el INS. El repositorio no tiene microdatos.
- ☐ **Reproducibilidad.** `renv::restore()` y luego `quarto render paper/` regeneran todas las cifras en una máquina limpia, con semillas fijas.
- ☐ **Diagnósticos completos.** Cada modelo reporta Ljung-Box, Jarque-Bera, ARCH-LM y estabilidad (raíces del VAR, Nyblom).

- ☐ **Descomposición consistente.** La participación de la atención se reporta con intervalo, y tiene el mismo signo y orden de magnitud en el panel y en la FEVD.
- ☐ **Placebo informado.** La serie interrumpida de chikungunya 2025 muestra atención alta con casos casi nulos, y su resultado se reporta, sea nulo o no.

Anexo A. Estructura del repositorio

El repositorio del grupo ya tiene los scripts 01–09; los nuevos siguen su numeración desde el 10. Cada uno lee lo que produjo el anterior con `here` y escribe en `data/`, como los actuales. Los 07, 08 y 09 se corrigen en su lugar, y Git guarda la versión anterior.

Tabla 9. Scripts corregidos y nuevos, responsable y fase.

Script	Contenido	Responsable	Fase
`07_serietemporal_conimputacion.R` (corregido)	Semanas sin casos con cero explícito; código 01 aparte; filtro de `ajuste` si corresponde; edad en años según `uni_med`	P1	0
`08_econometria.R` (corregido)	Box-Cox dentro de `auto.arima`, ventana reservada, MASE en casos; ARCH-LM y Ljung-Box con `fitdf` en vez de Breusch-Pagan y Durbin-Watson	P2	0
`09_complemento_econometria.R` (corregido)	VAR sobre 72 meses y alineado; GARCH sobre los residuos del SARIMA; sin MAPE copiado ni columna ńútilż escrita a mano	P2	0
`10_tasas_incidencia.R`	Tasas por 100.000 habitantes, ranking, agregación a regiones EMA	P1	0
`11_canal_endemico_tecnico.R`	Canal endémico, velas, SMA, EMA, Bollinger y MACD	P1	1
`12_indice_atencion.R`	Google Trends, GDELT y miedo excedente M	P3	1
`13_panel_ema.R`	Panel región-mes con controles	P2	1
`14_estacionariedad.R`	Box-Cox, ADF/KPSS, ACF/PACF de cada serie	P2	1
`15_panel_descomposicion.R`	Panel con efectos fijos, contribuciones y bootstrap de dos pasos	P2	2
`16_var_its_granger.R`	VAR nacional, FEVD, Granger y serie interrumpida	P2	2 y 3
`17_garch_volatilidad.R`	GARCH, GJR y EGARCH semanal	P3	2
`18_capm_eventos.R`	CAPM regional y bursátil, beta de portafolio, estudio de eventos	P2 y P3	2 y 3
`19_var_cvar_simulacion.R`	VaR, CVaR, tres simulaciones y backtesting	P3	3
`20_markowitz.R`	Fronteras eficientes, isomedia e isovarianza	P3	3
`21_logit_probit.R`	Scorecard de severidad y probit de alerta	P1	2 y 3
`22_riesgo_credito.R`	Cartera por departamento y pérdida esperada	P1	3
`paper/`	Paper y presentación en Quarto	todos	4
`data/MANIFIESTO.md`	Fuente, fecha y SHA-256 de cada base; reemplaza la ńfecha de descargaż que el README deja en blanco	todos	0 y 1

Anexo B. Esqueletos de código en R

Son puntos de partida, no código terminado, y no se han ejecutado. B.1 y B.7 usan los objetos y columnas del repositorio del grupo (`serie_dengue`, `dpto`, `fecha_sem`, `casos`, `pac_hos`, ...). En los demás, los nombres (`region`, `t`, ...) son supuestos y hay que ajustarlos al panel que se construya.

B.1 Series completas y evaluación en casos (P1 y P2)

```
library(tidyverse); library(here); library(forecast); library(vars)
serie_dengue <- readRDS(here("data", "series", "serie_dengue.rds"))
serie_chik   <- readRDS(here("data", "series", "serie_chik.rds"))

# Calendario de 314 semanas: la serie nacional de dengue no tiene huecos
semanas <- serie_dengue |> filter(dpto == "NACIONAL") |> distinct(anio, semana, fecha_sem)

completar <- function(serie) {                  # cada dpto con sus 314 semanas, cero si no hubo casos
  expand_grid(dpto = unique(serie$dpto), semanas) |>
    left_join(dplyr::select(serie, dpto, anio, semana, fecha_sem, casos),
              by = c("dpto", "anio", "semana", "fecha_sem")) |>
    mutate(casos = coalesce(casos, 0L))
}
a_mensual <- function(serie) serie |> filter(dpto == "NACIONAL") |>
  count(mes = floor_date(fecha_sem, "month"), wt = casos, name = "casos")

mensual_dengue <- a_mensual(completar(serie_dengue))
mensual_chik   <- a_mensual(completar(serie_chik))
stopifnot(nrow(mensual_dengue) == 72, nrow(mensual_chik) == 72)   # ningún mes se pierde

# SARIMA con Box-Cox dentro del modelo: pronóstico y errores en casos, fuera de muestra
y   <- ts(mensual_dengue$casos, start = c(2020, 1), frequency = 12)
fit <- auto.arima(window(y, end = c(2024, 12)), lambda = "auto", biasadj = TRUE)
accuracy(forecast(fit, h = 12), window(y, start = c(2025, 1)))     # MASE y MAPE en casos
checkresiduals(fit)                             # Ljung-Box con los grados de libertad del modelo

# VAR: fitted() empieza en el mes p + 1, así que el dato real se recorta antes de comparar
Y    <- cbind(dengue = mensual_dengue$casos, chik = mensual_chik$casos)
v    <- VAR(Y, p = 4, type = "const")
real <- Y[-(1:v$p), ]
mean(abs(real[, "dengue"] - fitted(v)[, "dengue"]) / real[, "dengue"])   # MAPE alineado
```

B.2 Canal endémico por el método de Bortman (P1)

```
library(dplyr)
# historia: casos por región y semana epidemiológica en los años previos, sin años de brote
canal <- historia |>
  group_by(region, semana) |>
  summarise(m = mean(log(casos + 1)), s = sd(log(casos + 1)), n = n(), .groups = "drop") |>
  mutate(h     = qt(0.975, n - 1) * s / sqrt(n),
         media = exp(m) - 1,
         inf   = exp(m - h) - 1,     # soporte: borde de la zona de éxito
         sup   = exp(m + h) - 1)     # resistencia: umbral de brote
```

B.3 Miedo excedente y panel con efectos fijos (P3 y P2)

```
library(fixest)
# Paso 1: la atención que explican los casos y las búsquedas de síntomas
aux <- feols(A ~ l(I, 0:3) + S | region^mes, data = panel, panel.id = ~ region + t)
panel$M <- NA
panel$M[obs(aux)] <- resid(aux)                 # miedo excedente

# Paso 2: rezagos predeterminados, estacionalidad por región y errores Driscoll-Kraay
m <- feols(Y ~ l(I, 1:3) + l(M, 1:3) + l(lluvia, 1) + l(temp, 1) | anio_mes + region^mes,
           data = panel, panel.id = ~ region + t, vcov = "DK")
etable(m)
# El bootstrap repite los pasos 1 y 2 en cada réplica, remuestreando bloques de meses
```

B.4 GARCH semanal con la atención en la varianza (P3)

```
library(rugarch)
r <- diff(log(casos_sem + 1))                    # rendimiento epidémico semanal
x <- as.matrix(M_sem_rezagada)                   # M de la semana anterior, misma longitud que r
spec <- ugarchspec(
  mean.model     = list(armaOrder = c(2, 0)),    # orden según ACF y PACF
  variance.model = list(model = "eGARCH", garchOrder = c(1, 1), external.regressors = x),
  distribution.model = "std")
fit <- ugarchfit(spec, data = r)
infocriteria(fit)[1] * length(r)                 # AIC en la escala de arima(): -2 lnL + 2k
```

B.5 VaR, CVaR, bootstrap por bloques y backtesting (P3)

```
library(boot)
# perdida: pérdida semanal estimada de una región, en millones de pesos
var_h  <- quantile(perdida, 0.95)
cvar_h <- mean(perdida[perdida >= var_h])

sim <- ugarchsim(fit, n.sim = 52, m.sim = 5000)  # Montecarlo: 5000 trayectorias de 52 semanas
tray <- fitted(sim)                              # matriz 52 x 5000 de rendimientos simulados

cvar <- function(x, a = 0.95) mean(x[x >= quantile(x, a)])
b <- tsboot(perdida, function(x) c(quantile(x, 0.95), cvar(x)),
            R = 2000, l = 8, sim = "fixed")      # bloques de 8 semanas
boot.ci(b, type = "perc", index = 2)             # intervalo del CVaR

# rugarch prueba la cola izquierda: pérdidas y VaR se pasan con signo negativo
VaRTest(alpha = 0.05, actual = -perdida_obs, VaR = -var_pronosticado)
# uc.LRp = Kupiec (cobertura incondicional); cc.LRp = Christoffersen (independencia)
```

B.6 Frontera eficiente con regiones como activos (P3)

```
library(quadprog)
# mu: crecimiento medio de la ocupación por región; S: su matriz de covarianzas
peso_min_var <- function(mu, S, objetivo) {
  n <- length(mu)
  A <- cbind(rep(1, n), mu, diag(n))             # suma 1, media objetivo, w >= 0
  solve.QP(Dmat = 2 * S, dvec = rep(0, n), Amat = A,
           bvec = c(1, objetivo, rep(0, n)), meq = 2)$solution
}
objetivos <- seq(min(mu), max(mu), length.out = 50)
frontera <- t(sapply(objetivos, function(o) {
  w <- peso_min_var(mu, S, o)
  c(media = sum(w * mu), sd = sqrt(drop(t(w) %*% S %*% w)))
}))
# Repetir con S de meses epidémicos y de meses normales, y comparar las dos fronteras
```

B.7 Scorecard de severidad logit y probit (P1)

```
library(tidyverse); library(here); library(pROC)
# Base preparada en 02, ANTES de la imputación: el estrato faltante queda como categoría propia
datos <- readRDS(here("data", "processed", "dengue_prep.rds")) |>
  mutate(hosp     = as.integer(pac_hos == "1"),
         estrato  = fct_na_value_to_level(factor(estrato), level = "Sin dato"),
         edad_a   = case_when(uni_med == "1" ~ edad,            # años
                              uni_med == "2" ~ edad / 12,       # meses
                              uni_med == "3" ~ edad / 365.25,   # días
                              uni_med %in% c("4", "5") ~ 0))    # horas o minutos
set.seed(123)
en_entrena <- runif(nrow(datos)) < 0.7
entrena <- datos[en_entrena, ];  prueba <- datos[!en_entrena, ]

logit  <- glm(hosp ~ edad_a + I(edad_a^2) + sexo + estrato + tip_ss + area,
              family = binomial("logit"), data = entrena)
probit <- update(logit, family = binomial("probit"))
p     <- predict(logit, newdata = prueba, type = "response")
curva <- roc(prueba$hosp, p)
gini  <- 2 * auc(curva) - 1
ks    <- max(abs(ecdf(p[prueba$hosp == 1])(p) - ecdf(p[prueba$hosp == 0])(p)))
marginaleffects::avg_slopes(logit)              # efectos marginales promedio
```

B.8 Acceso a Google Trends, GDELT y datos.gov.co (P3 y P1)

```
library(gtrendsR); library(httr2)
# Google Trends: dos ventanas de 5 años que se solapan, para conservar el dato semanal.
# El geo departamental (CO-VAC) es justo lo que se prueba el día 1.
g1 <- gtrends("brote dengue", geo = "CO-VAC", time = "2020-01-01 2024-12-31")
g2 <- gtrends("brote dengue", geo = "CO-VAC", time = "2021-01-01 2025-12-31")
# Reescalar g2 a la escala de g1 con la razón de medias en el tramo común (2021-2024)

# GDELT DOC 2.0: volumen de noticias sobre dengue en medios de Colombia
gd <- request("https://api.gdeltproject.org/api/v2/doc/doc") |>
  req_url_query(query = "dengue sourcecountry:CO", mode = "timelinevol", format = "json",
                startdatetime = "20200101000000", enddatetime = "20251231235959") |>
  req_perform() |> resp_body_json()

# Superfinanciera en datos.gov.co (API Socrata)
cartera <- request("https://www.datos.gov.co/resource/u2wk-tfe3.json") |>
  req_url_query(`$limit` = 50000) |>
  req_perform() |> resp_body_json(simplifyVector = TRUE)
```

Anexo C. Glosario

Tabla 10. Términos usados en este documento.

Término	Significado aquí
ARCH-LM	Prueba de heterocedasticidad condicional sobre los residuos al cuadrado; es la que justifica un GARCH
AUC, KS y Gini	Medidas de discriminación de un scoring: área bajo la curva ROC, máxima distancia entre las distribuciones de buenos y malos, y $2\,\text{AUC} - 1$
Beta (β)	Sensibilidad de un activo, o de una región, a su mercado de referencia: es el riesgo sistemático. Lo que queda en el residuo es el riesgo no sistemático o idiosincrático
Bootstrap por bloques	Remuestreo de tramos consecutivos de la serie, que conserva su autocorrelación
Canal endémico	Bandas semanales de lo ńesperadoż según los años previos. Con el método de Bortman, la media geométrica y su IC del 95 % definen las zonas de éxito, seguridad, alerta y brote
Driscoll-Kraay	Errores estándar de panel robustos a correlación entre unidades y en el tiempo
EMA	Encuesta Mensual de Alojamiento del DANE: ocupación hotelera mensual en 12 regiones
Efectos fijos	Interceptos propios de cada región, de cada mes o de cada región-mes del año, que absorben lo que no cambia en esa dimensión
FEVD	Descomposición de la varianza del error de pronóstico: qué fracción de la incertidumbre de una variable viene de cada choque del VAR
GDELT	Base abierta que monitorea noticias del mundo; su API DOC 2.0 da volumen y tono diarios desde 2017
GJR-GARCH y EGARCH	Variantes del GARCH que permiten que los choques positivos y negativos muevan la volatilidad de forma distinta
INGARCH	Modelo GARCH para conteos (Poisson o binomial negativa), adecuado para series con ceros
Isomedia e isovarianza	Rectas de igual rendimiento esperado y curvas de igual varianza en el plano de los pesos de un portafolio
Kupiec y Christoffersen	Pruebas de backtesting del VaR: la primera mira si la proporción de excesos es la esperada; la segunda, además, si los excesos son independientes
MASE	Error absoluto medio escalado por el de un pronóstico ingenuo; funciona con ceros, a diferencia del MAPE
Miedo excedente (M)	Parte de la atención que no explican la incidencia local, sus rezagos, las búsquedas de síntomas ni la estacionalidad
Orden de Cholesky	Supuesto de qué variable del VAR reacciona primero dentro del mismo mes; aquí, incidencia, luego atención, luego economía
Pérdida esperada	$EL = PD \times LGD \times EAD$: el producto de la probabilidad de incumplimiento, la pérdida dado el incumplimiento y la exposición en el momento del incumplimiento
Placebo	Episodio donde se espera un resultado conocido (aquí, miedo sin casos) y que sirve para probar el diseño
Semana de notificación e inicio de síntomas	Dos formas de fechar un caso: cuando el SIVIGILA lo recibe y cuando la persona enfermó. La primera es la que reportan los boletines; la segunda sigue mejor la epidemia
Serie interrumpida	Comparación de lo observado después de un choque con el pronóstico de un modelo ajustado antes de él
VaR y CVaR	Pérdida que solo se supera con probabilidad α, y pérdida promedio cuando se supera

Anexo D. Fuentes verificadas el 8 de octubre de 2026

Tabla 11. Lo que se verificó, el resultado y la fuente.

Qué se verificó	Resultado	Fuente
Escala del AIC en `rugarch`	Confirmado: $(-2\ln L)/n + 2k/n$	Código fuente de `rugarch`
GDELT DOC 2.0: alcance de las series de tiempo	Confirmado: `timelinevol` y `timelinetone` cubren desde el 1 de enero de 2017; sin filtro por departamento	Blog de GDELT
Google Trends: granularidad	Datos semanales solo en ventanas de hasta unos 5 años. La API oficial (alfa) cubre 1.800 días y se accede por solicitud. El nivel departamental para Colombia no se pudo confirmar	Towards Data Science; Google Search Central
Estado de `gtrendsR`	En CRAN (v1.5.2, agosto de 2025), con reportes de errores 429	CRAN
Cartera por departamento (Superfinanciera)	Conjunto `u2wk-tfe3`: trimestral, por departamento y municipio, categorías A a E, sin columna de cartera vencida; actualizado el 10 de septiembre de 2026	datos.gov.co
DANE EMA	Mensual, 12 regiones (no 32 departamentos); empalme de la MMH a la EMA en 2020	Boletín EMA, julio de 2026
Canal endémico del INS	Método de Bortman (media geométrica con IC del 95 %), zonas de éxito, seguridad, alerta y brote	INS, informe de dengue, periodo I de 2024
Brotes de chikungunya de 2025	La Reunión (marzo–abril), Foshan (declarado el 9 de julio), alertas de la OPS (13 y 28 de agosto), Cuba (julio–diciembre, pico en octubre–noviembre)	OMS, DON567; Emerging Infectious Diseases; Diario de Cuba
`fwildclusterboot`	Archivado en CRAN el 29 de mayo de 2024	CRAN
Repositorio del grupo	Público. Scripts 01–09, `renv.lock` y series semanales agregadas; las series suman 748.037 y 419 casos. Errores de código en 02 y 06–09 (Tabla 2 y ğ6) y microdatos versionados en `data/processed/`	GitHub, revisado el 8 de octubre

USTA 2026-II — Universidad Santo Tomás
Dirige:
8 de octubre de 2026